



UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Departamento de Ciência da Computação

Curso de Graduação em Computação

Álvaro Lima - 2021067062

Daniele Diniz - 2020076874

Igor Joaquim - 2021032218

Ivan Assis - 2021421931

Vitor Emanuel - 2021032072

**Antecipando o Apito: A Correlação entre o Sentimento em Tempo
Real e Eventos de Campo em Transmissões Digitais**

Belo Horizonte

2026

Antecipando o Apito: A Correlação entre o Sentimento em Tempo Real e Eventos de Campo em Transmissões Digitais

Trabalho apresentado à disciplina DCC071 e Ciência de Dados Aplicada ao Futebol, do Curso de graduação em Computação do Departamento de Ciência da Computação do Instituto de Ciências Exatas da UFMG, como requisito parcial à conclusão da disciplina.

Professor (a): Adriano, Wagner e Ricardo

Proposta

1. Introdução e Contexto

É comum observar, em transmissões esportivas e debates pós-jogo, a percepção de que a torcida reage de forma predominantemente emocional, sendo frequentemente caracterizada como “passional” ou pouco alinhada a análises táticas e estatísticas do futebol. Comentaristas, analistas e veículos de mídia frequentemente sugerem que o torcedor médio não capta nuances mais complexas do jogo, baseando suas opiniões em eventos pontuais ou impressões momentâneas.

Entretanto, o consumo de futebol passou recentemente por uma transição de paradigma com o surgimento de transmissões via streaming interativo, como a CazéTV. Nessas plataformas, o chat em tempo real atua como uma verdadeira “arquibancada digital”, gerando um fluxo contínuo de dados não estruturados que capturam, em alta frequência, a reação imediata da torcida durante a partida.

Esse novo contexto cria uma oportunidade inédita: ao invés de tratar a manifestação do torcedor apenas como ruído ou percepção subjetiva, torna-se possível analisá-la quantitativamente. Em particular, técnicas de processamento de linguagem natural permitem extrair sinais de sentimento coletivo a partir dessas interações, possibilitando sua representação como uma série temporal alinhada ao andamento do jogo.

Dessa forma, este trabalho propõe utilizar a análise de sentimento do chat como um potencial “sensor coletivo” de desempenho, cruzando-o com métricas de processo do jogo para investigar a dinâmica entre a percepção do público e a realidade estatística em campo. Mais especificamente, busca-se analisar em que medida o comportamento emocional agregado da torcida reflete variações no desempenho das equipes e se apresenta padrões temporalmente correlacionados, ou potencialmente antecedentes, a eventos observados durante a partida.

2. Exploração Inicial e Tomada de Decisão

Durante a fase de planejamento e entendimento do negócio, realizamos uma busca por fontes de dados que permitissem a reprodutibilidade do estudo. Identificamos que o acesso a

transmissões completas com chat preservado é restrito em muitos canais estrangeiros por questões de direitos autorais.

Em contrapartida, identificamos na **CazéTV** uma [playlist](#) robusta de jogos da **Bundesliga 24/25** com transmissões brasileiras e chats arquivados. Essa descoberta foi fundamental para definirmos as seguintes decisões técnicas:

- **Volume de Dados:** O chat da CazéTV apresenta uma densidade de comentários alta, o que reduz o ruído estatístico após o processo de janelamento.
- **Disponibilidade de Dados de súmula:** A **Bundesliga** é um campeonato bastante estudado na literatura, logo é possível encontrar bases públicas com métricas de desempenho.
- **Língua e Modelo:** Optamos pelo português brasileiro, utilizando o modelo **XLM-roBERTa** (um modelo BERT multilíngue com versões focadas em redes sociais). Isso nos permite captar gírias, sarcasmo e nuances do torcedor local com maior precisão do que modelos genéricos.

3. Perguntas de Pesquisa

RQ1: *Qual é a correlação temporal entre o sentimento coletivo agregado no chat de transmissões ao vivo e métricas de desempenho em campo, como xT e Momentum?*

RQ2: *Existem padrões de variação de sentimento que precedem, de forma estatisticamente significativa, eventos discretos críticos da partida (gols, cartões) ?*

4. Metodologia

O núcleo técnico deste trabalho consiste em alinhar três camadas distintas de informação: o texto do chat, os eventos discretos da partida e as métricas contínuas de desempenho ao longo de uma partida. Para garantir o rigor analítico e a testabilidade das hipóteses, a metodologia foi estruturada em quatro etapas fundamentais: a obtenção dos dados de campo, a adaptação do processamento de linguagem, a agregação temporal do sentimento e a análise estatística.

Coleta do Chat do YouTube

A captura da "arquivancada digital" requer a extração sistemática das interações síncronas durante a transmissão ao vivo. Para isso, utilizaremos bibliotecas especializadas em raspagem de dados de transmissões ou a própria API Data v3 do YouTube, garantindo a captura não apenas do conteúdo textual de cada mensagem, mas fundamentalmente do seu timestamp exato. Este metadado temporal é a espinha dorsal que viabiliza a sincronização posterior.

Imediatamente após a coleta, o corpus bruto passará por uma rigorosa rotina de sanitização para mitigar ruídos. Esta etapa inclui a exclusão de bots moderadores, a remoção de mensagens automáticas de adesão de membros e a filtragem de spams mecânicos. Além disso, o conjunto de dados será anonimizado na origem. Identificadores pessoais (usernames e URLs de perfil) serão substituídos por hashes criptográficos irreversíveis, assegurando que o estudo análise exclusivamente a dinâmica das massas, sem margem para a re-identificação ou rastreamento individual dos torcedores.

id_msg	id_partida	timestamp	texto	sentimento	classificacao
1	GERxBAY	00:15:30	<i>"Vamoos pra cima deles!"</i>	0.92	Positivo
2	GERxBAY	00:15:32	<i>"Esse juiz é muito caseiro, pqp"</i>	-0.85	Negativo
3	GERxBAY	00:15:35	<i>"Tira esse bagre do time logo"</i>	-0.78	Negativo

A fim de sincronizar o tempo dos comentários da live do YouTube com o tempo real de partida, precisamos saber em quanto tempo de transmissão a partida realmente aconteceu. Por exemplo, se o primeiro tempo de uma partida começa aos 34 minutos da transmissão, um comentário aos 36 minutos será, ao mesmo tempo, um comentário feito no minuto 2 da partida. Como estamos tratando de vídeos do YouTube, o placar da transmissão na maioria das vezes mostra o tempo de relógio corrido. Dessa forma, ao encontrar qual o tempo de relógio de um frame específico do vídeo, podemos identificar os timestamps de início de cada tempo.



Figura. [Frame do vídeo](#) aos 39:52

Note que o timer mostra 03:59 - logo a partida começou no minuto 35:53



Figura. Placar usado para OCR


Coleta dos Dados de Súmula e Desempenho

Para correlacionar o sentimento da torcida com o que de fato ocorre no campo, utilizaremos dados de eventos provenientes de bases de dados estatísticos esportivos consolidadas. Essa etapa é crucial para a extração precisa dos timestamps de eventos discretos, como gols,


cartões e substituições. A obtenção desses dados servirá como a nossa variável dependente de eventos, criando a base numérica que será cruzada com as reações do público. Por exemplo:

- Gols marcados (e gols anulados).
- Pênaltis assinalados.
- Cartões vermelhos (expulsões diretas ou segundo amarelo).
- Cartões amarelos por faltas duras ou reclamação.
- Substituições de jogadores.

Todos esses dados devem estar acompanhados do tempo de relógio que o evento ocorreu. A fim de criar uma série temporal



Pensando em dados de Desempenho contínuos, duas métricas prevalecem como mais úteis, o *xT (Expected Threat)* e o *Momentum*.




Processamento de Linguagem Natural e Adaptação de Domínio

Para a análise de sentimento no chat do YouTube, usaremos o [cardiffnlp/twitter-xlm-roberta-base-sentiment](#), escolhido por sua robustez e treinamento em tweets em português. O principal desafio é a semântica do jargão esportivo ("futebolês"), onde termos geralmente ofensivos podem indicar euforia. Para mitigar esse problema e validar o modelo em nosso corpus, desenvolveremos um Gold Standard. Este procedimento consistirá na anotação manual prévia da polaridade de uma amostra aleatória representativa de mensagens (aproximadamente 800 a 1000 interações). Isso nos permitirá calcular o F1-Score inicial do modelo e, caso o desempenho seja insatisfatório, realizar o fine-tuning da ferramenta ou acoplar um léxico específico de futebol antes da classificação em larga escala.

Para otimizar a construção desse Gold Standard e potencializar o fine-tuning, adotaremos uma abordagem de Active Learning (Aprendizado Ativo) assistida pelo modelo de linguagem Qwen. Em vez de depender de uma amostra puramente aleatória, utilizaremos o modelo em um ciclo iterativo para identificar e filtrar as mensagens de maior complexidade e incerteza semântica (como sarcasmos profundos e inversões de polaridade). Atuando como um LLM-as-a-judge, o Qwen fornecerá rótulos preliminares e justificativas para os comentários mais desafiadores da transmissão. Posteriormente, essa amostra seletiva passará por validação

humana. Essa estratégia reduz drasticamente o esforço braçal de anotação e garante que o modelo roBERTa seja treinado exatamente com as interações mais informativas, acelerando a convergência e a precisão do pipeline final.




Agregação Temporal

Uma vez resolvida a etapa semântica, lidaremos com a natureza inerentemente ruidosa do chat ao vivo (composto por spams, repetições mecânicas e excesso de emojis) abdicando da análise de comentários isolados em favor da técnica de Agregação por Janelas Temporais. A nossa estratégia consiste em agrupar as mensagens em janelas fixas, que variam empiricamente de 10 segundos a 2 minutos. Para cada janela T , calculamos um índice que transforma as linhas de texto em uma variável contínua, dada pela equação:

$$Polaridade(T) = \frac{Positivas(T) - Negativas(T)}{Total(T) + \epsilon}$$

onde ϵ previne divisão por zero em janelas vazias.



Para mitigar o viés de falsos positivos em janelas de baixa interatividade, esta pesquisa adotará uma abordagem bidimensional. Além da *Polaridade(T)* extraída via roBERTa, incorporamos o volume de mensagens como proxy para o nível de excitação da audiência. Isso nos permitirá formular um índice garantindo que picos de positividade ou negatividade só tenham relevância estatística quando acompanhados por engajamento massivo da comunidade.

- **Alto Volume + Alta Polaridade:** Euforia (Gol, drible plástico, defesa de pênalti).
- **Alto Volume + Baixa Polaridade:** Estresse/Revolta (Erro de arbitragem, VAR, gol do adversário, chance clara perdida).
- **Baixo Volume + Polaridade Neutra/Positiva:** Tédio/Expectativa (Toque de bola na zaga).
- **Baixo Volume + Baixa Polaridade:** Tensão (Adversário dominando o jogo, "sufoco").

É possível juntar ambas as métricas em uma só, chamada de “Engagement-Weighted Sentiment Index”

$$WSI(T) = Polaridade(T) * \log[1 + V(T)]$$

Sincronização e Alinhamento

A etapa final e mais crítica para validar a hipótese de "antecipação" é o alinhamento das variáveis. Como o tempo de vídeo no YouTube não corresponde ao relógio do provedor de dados estatísticos, e considerando a latência orgânica das transmissões via streaming

(frequentemente entre 15 a 30 segundos de atraso em relação à vida real), realizaremos um emparelhamento matemático.

Para transcender a mera observação de co-ocorrência e provar que o chat atua como um indicador antecedente, não usaremos correlações lineares simples. Em vez disso, aplicamos métodos avançados de séries temporais, estabelecendo, assim, se os padrões no índice de polaridade efetivamente precedem e preveem as flutuações de desempenho no gramado.

5 . Delimitação do escopo do problema de pesquisa

Dada a complexidade do problema e a diversidade de possíveis abordagens, este trabalho adota uma delimitação clara de escopo, priorizando a análise da relação entre o sentimento coletivo da torcida e o desempenho das equipes ao longo da partida.

O foco principal consiste na investigação da correlação temporal entre o sentimento agregado do chat, obtido por meio de técnicas de análise de sentimento aplicadas a mensagens em tempo real, e métricas contínuas de desempenho em campo, em especial o *Expected Threat (xT)* e o *Momentum*. Essa abordagem busca compreender em que medida a variação do sentimento coletivo acompanha ou reflete mudanças na progressão ofensiva e no controle do jogo pelas equipes ao longo do tempo.

Como objetivo complementar, o trabalho também analisa a relação entre variações significativas no sentimento e a ocorrência de eventos discretos da partida, como gols e cartões. Nesse contexto, busca-se identificar padrões temporais que indiquem se alterações no sentimento coletivo ocorrem antes, durante ou após tais eventos.

Dessa forma, o estudo concentra-se prioritariamente na análise de correlação temporal com métricas contínuas, enquanto a investigação envolvendo eventos discretos é tratada como uma análise complementar, com o objetivo de enriquecer a compreensão da dinâmica entre percepção coletiva e acontecimentos em campo.

6. Trabalhos relacionados

A fundamentação teórica deste trabalho baseia-se na interseção entre a Computação Social e a Ciência de Dados Esportivos, áreas que têm utilizado as redes sociais como "sensores" para capturar a dinâmica emocional das massas em tempo real.

Análise de Sentimento no Contexto do Futebol

A análise de sentimento aplicada ao futebol tem sido explorada predominantemente a partir de dados do Twitter, visando compreender a reação dos torcedores e a sumarização de eventos. No que tange à identificação de momentos críticos, o trabalho de Andaloussi et al. (2015) propõe um framework para o resumo automático de partidas baseado em eventos de sentimento no Twitter, demonstrando que variações na polaridade das mensagens são proxies eficazes para gols e decisões arbitrais. De forma complementar, pesquisas como as de She et al. (2023) e Patel e Passi (2020) utilizaram modelos de Machine Learning e algoritmos como o VADER para mapear como o sentimento coletivo evolui antes e durante grandes competições como a Copa do Mundo, revelando padrões claros de reação a eventos de jogo.

Para além da descrição, a literatura busca capacidades preditivas. O estudo de Miranda-Peña et al. (2021) explora o uso de sentimento agregado e teoria dos grafos para prever desfechos de partidas da Premier League, sugerindo que o comportamento coletivo contém sinais úteis para inferência sobre resultados finais. Na mesma linha, Almeida (2023) reforça a viabilidade de utilizar o conhecimento coletivo (wisdom of the crowd) extraído de redes sociais para antecipar eventos esportivos através de redes neurais.

Entretanto, o domínio do futebol apresenta desafios semânticos únicos. Aloufi e El Saddik (2018) destacam que modelos genéricos frequentemente falham ao interpretar o "futebolês" (gírias e sarcasmo), evidenciando a necessidade de léxicos específicos para o domínio. Adicionalmente, Alhadlaq e Alnuaim (2023) analisaram diferenças culturais na expressão emocional entre torcedores árabes e hispânicos, mostrando que, embora existam variações linguísticas, a estrutura da evolução do sentimento coletivo mantém padrões identificáveis globalmente. Recentemente, pesquisadores como Mahmud et al. (2025) começaram a expandir essas análises para o YouTube, reconhecendo a riqueza das interações em chats de transmissões ao vivo.

Análise de Sentimento em Outros Domínios

A premissa de que dados textuais capturam dinâmicas subjacentes de sistemas complexos é validada em outros campos. No contexto científico, o estudo de Hassan et al. (2019) demonstra que o sentimento expresso em redes sociais sobre artigos acadêmicos pode atuar como um indicador precoce de seu impacto futuro e citações.

De forma análoga, no setor financeiro, o trabalho de Guo e Xie (2024) investiga a correlação entre o sentimento no Twitter e as variações no mercado de ações através de Deep Learning. Os autores provam que o sentimento agregado não apenas reflete o estado atual do mercado, mas possui valor preditivo para movimentos de preço. Esses estudos reforçam a hipótese central deste trabalho: grandes volumes de dados gerados por usuários em tempo real capturam sinais emergentes que antecedem ou explicam flutuações em métricas tradicionais.

7. Escopo e Seleção de Casos

Em vez de analisar muitos jogos com poucos dados, selecionaremos **65 partidas de alto engajamento** (com maior número de espectadores e curtidas) para que tenhamos uma amostra grande o suficiente de comentários para poder fazer nossa análise.

8. Resultados Esperados

Com a execução desta pesquisa, espera-se, primariamente, validar a hipótese de que o chat das transmissões ao vivo funciona como um sensor coletivo altamente responsivo, capaz de refletir a dinâmica de desempenho em campo com uma granularidade superior à das redes sociais assíncronas.

No que tange à **RQ1**, antecipamos a identificação de uma correlação estatisticamente significativa entre o **Índice de Polaridade** agregado e as métricas contínuas de ***Expected Threat (xT)*** e ***Momentum***. Espera-se que períodos de pressão ofensiva sustentada, mesmo sem a ocorrência imediata de gols, geram uma curva ascendente de sentimento positivo ou de alta excitação, demonstrando que a "arquibancada digital" percebe e reage a nuances táticas e de volume de jogo que não são capturadas por sùmulas simplificadas.

Quanto à **RQ2**, o resultado esperado mais ambicioso é a demonstração de que as flutuações de sentimento no chat possuem valor preditivo sobre eventos discretos e variações bruscas no

desempenho. Acredita-se que o comportamento da massa digital apresenta padrões de "clímax" ou "tensão" que precedem estatisticamente momentos críticos, como gols e expulsões, validando o chat como um indicador antecedente. Este resultado consolida a ideia de que a percepção coletiva processa o contexto do jogo (como um contra-ataque promissor ou uma falha defensiva iminente) antes mesmo da conclusão do evento físico.

No plano metodológico, espera-se que o trabalho entregue um framework validado de sincronização entre streaming e dados de campo, corrigindo distorções de tempo. Adicionalmente, espera-se comprovar que o uso do modelo roBERTa atinja uma acurácia superior na captura do "futebolês" e do sarcasmo, estabelecendo um novo padrão para o processamento de sentimentos em contextos esportivos brasileiros.

Por fim, os resultados devem oferecer insights valiosos para a governança de plataformas e para o setor de transmissão (broadcasting), evidenciando como o engajamento em tempo real pode ser utilizado para prever picos de tráfego, moderar comportamentos tóxicos em momentos de alta tensão e enriquecer a experiência do espectador através de métricas de "termômetro de jogo" baseadas em evidências científicas.

9. Referências

- ALHADLAQ, A.; ALNUAIM, A. A. A Twitter-Based Comparative Analysis of Emotions and Sentiments of Arab and Hispanic Football Fans. *Applied Sciences*, v. 13, n. 11, p. 6729, 2023. Disponível em: <https://doi.org/10.3390/app13116729>.
- ALMEIDA, T. F. P. D. Predicting sports events using Twitter sentiment analysis and neural networks. 2023. 84 f. Dissertação (Mestrado em Engenharia Informática e de Computadores) – Instituto Superior Técnico, Universidade de Lisboa, Lisboa, 2023.
- ALOUFI, S.; EL SADDIK, A. Sentiment Identification in Football-Specific Tweets. *IEEE Access*, v. 6, p. 78609-78621, 2018. Disponível em: <https://doi.org/10.1109/ACCESS.2018.2885117>.
- ANDALOUSSI, S. J. et al. Soccer Events Summarization by Using Sentiment Analysis. In: 2015 International Conference on Computational Science and Computational Intelligence (CSCI), Las Vegas, NV, USA, p. 59-64, 2015. Disponível em: <https://doi.org/10.1109/CSCI.2015.59>.

- GUO, K.; XIE, H. Deep learning in finance assessing twitter sentiment impact and prediction on stocks. PeerJ Computer Science, v. 10, p. e1801, 2024. Disponível em: <https://doi.org/10.7717/peerj-cs.1801>.
- MAHMUD, M. et al. Sport Sentiment Analysis of Twitter(X) Post's and YouTube Comments Using Machine Learning Algorithm. In: 2025 International Conference on Quantum Photonics, Artificial Intelligence, and Networking (QPAIN), 2025. Disponível em: <https://doi.org/10.1109/QPAIN66474.2025.11171758>.
- MIRANDA-PEÑA, C. et al. Predicting Soccer Results Through Sentiment Analysis: A Graph Theory Approach. In: Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), v. 12747, p. 336-347, 2021. Disponível em: https://doi.org/10.1007/978-3-030-77980-1_32.
- PATEL, R.; PASSI, K. Sentiment Analysis on Twitter Data of World Cup Soccer Tournament Using Machine Learning. IoT, v. 1, n. 2, p. 14, 2020. Disponível em: <https://doi.org/10.3390/iot1020014>.
- SHE, J. et al. What Sentiment and Fun Facts We Learnt Before FIFA World Cup Qatar 2022 Using Twitter and AI. arXiv preprint arXiv:2306.16049, 2023. Disponível em: <https://doi.org/10.48550/arXiv.2306.16049>.