

CDAF: Análise Exploratória de Dados (EDA) - YouTube Live Chat

Projeto: Monitoramento de Engajamento e Sentimento na Bundesliga 24/25 (CazéTV)

Disciplina: Coleta e Demonstração de Arquivos de Futebol (CDAF)

Integrantes: Álvaro Lima, Daniele Diniz, Igor Joaquim, Ivan Assis, Vitor Emanuel

Data: Maio de 2026

1. Introdução



Este notebook apresenta os resultados do **Trabalho Prático 2 (TP2)**, focado na análise exploratória de um corpus massivo de mensagens ($N > 240$ mil) coletadas do chat ao vivo do YouTube durante as transmissões da Bundesliga 24/25.

O objetivo é quantificar a resposta emocional do público em tempo real. Para isso, implementamos uma arquitetura de aprendizado híbrida:

1. **Destilação de Conhecimento (vLLM):** Utilizamos o modelo **Qwen 2.5 7B** com *Chain-of-Thought (CoT)* para rotular mensagens complexas, capturando nuances do "futebolês" (ex: "Bagre", "Operação").
2. **Classificação em Larga Escala:** Fine-tuning do modelo **BERTimbau** (*BERT Base Portuguese*) sobre os rótulos gerados, otimizando a latência de inferência para o processamento de todo o dataset.

2. Análise da Camada de Metadados


Avaliamos o alcance das transmissões da CazéTV para identificar o potencial de engajamento do dataset. A distribuição de visualizações revela a escala do canal, enquanto a frequência de clubes indica as equipes mais presentes no conjunto de dados.



Análise de Distribuição e Viés de Exposição


Os gráficos acima apresentam dois aspectos fundamentais do ecossistema de dados:

- Volume de Audiência:** A distribuição de visualizações é assimétrica à direita, com a maioria dos vídeos concentrada na faixa de centenas de milhares de visualizações, mas com *outliers* significativos ultrapassando a marca de 1 milhão.
- Concentração de Clubes:** Há uma predominância de clubes como **Bayern de Munique** e **Bayer Leverkusen**, refletindo a estratégia de transmissão focada em equipes de maior apelo comercial ou em disputa por títulos.



Análise de Temporalidade

A curva temporal de visualizações revela a variação do engajamento ao longo da temporada. Picos de audiência coincidem com momentos importantes do calendário da Bundesliga. A estabilidade na base da curva demonstra a fidelização de uma audiência recorrente.



Análise de Correlação de Engajamento

O gráfico de dispersão confirma que o engajamento no chat está correlacionado à audiência do vídeo. Com um **Pearson R próximo a 0.77**, observamos uma tendência positiva clara. A variação no tamanho das bolhas (duração do vídeo) sugere que o tempo total de transmissão também influencia o volume total de mensagens acumuladas.


Sumário Estatístico dos Metadados

A tabela abaixo resume as métricas centrais de alcance e interatividade das transmissões analisadas.

	count	mean	std	min	25%	50%	75%	
view_count	55.0	745966.109091	346080.280841	280683.0	525118.0	692234.0	871063.5	22057
like_count	55.0	17560.236364	10323.566137	3962.0	10996.0	16624.0	20304.0	660
comment_count	55.0	7.745455	13.850014	1.0	3.0	5.0	8.0	1
chat_volume	55.0	3833.890909	2046.246923	669.0	2345.5	3179.0	5267.5	100
duration	55.0	10613.127273	1864.944732	8830.0	9165.0	9940.0	11340.0	170

3. Distribuição de Sentimento

Analizamos a distribuição das classes de sentimento preditas pelo modelo. A presença de mensagens neutras é comum em transmissões longas, onde parte das interações envolve compartilhamento de informações ou saudações casuais.




Análise de Composição de Sentimentos

A distribuição revela que as interações neutras representam uma parcela significativa (**38.1%**). O equilíbrio entre **Positivo (29.2%)** e **Negativo (32.7%)** reflete a dinâmica de uma partida de futebol, onde eventos favoráveis a uma equipe geram reações opostas nas torcidas envolvidas.

4. Dinâmica Temporal do Volume

Avaliamos o volume de mensagens por minuto de jogo. A curva média revela variações de intensidade que acompanham o andamento da partida, com aumentos de volume geralmente associados a momentos de maior expectativa ou eventos decisivos.



Análise de Fluxo Temporal

A dinâmica do volume apresenta padrões repetitivos:


1. **Engajamento Inicial:** Volume elevado nos primeiros minutos.
2. **Estabilidade:** Períodos de volume mais constante durante o desenvolvimento do jogo.
3. **Finais de Tempo:** Aumento de interações nos minutos finais de cada etapa.
4. **Intervalo:** Queda expressiva no volume de mensagens, conforme esperado.

5. Polaridade e Índice WSI

A polaridade bruta (P) indica o humor predominante, enquanto o **Engagement-Weighted Sentiment Index (WSI)** pondera o sentimento pelo volume de mensagens da janela temporal.

$$Polarity = \frac{Positivos - Negativos}{Total}$$

$$WSI(T) = Polarity(T) \times \log(1 + Volume(T))$$




Análise de Métricas de Sentimento

1. **Polaridade Média:** A curva agregada mostra oscilações frequentes. Nota-se que o sentimento tende a ser levemente negativo na média sazonal, refletindo críticas comuns durante as transmissões.
2. **Ajuste por Volume (WSI):** O índice WSI atua como uma métrica ponderada. Ambas as curvas são ruidosas, mas o WSI tende a reduzir a importância de variações ocorridas em janelas com pouca atividade, focando a análise no comportamento de massa.

6. Análise Lexical

Através das nuvens de palavras, observamos os termos mais frequentes em cada sentimento. A remoção de stopwords permite isolar palavras com maior carga de significado.



Insights Lexicais

A análise lexical revela termos típicos do chat da CazéTV:


- **Positivo:** Exclamações como "Gol" e "Boa", além de nomes de jogadores de destaque. O termo "Terno" é usado como elogio técnico.
- **Negativo:** Críticas à arbitragem e termos como "Bagre". Termos de apostas também aparecem em contextos de frustração com resultados.

O modelo captou corretamente o uso de gírias de nicho, permitindo uma análise que respeita o vocabulário real da comunidade.


7. Estudo de Caso: Partida de Maior Engajamento

Avaliamos o jogo de maior volume absoluto. Este estudo de caso permite observar as flutuações de sentimento em uma partida individual de alto impacto.

Variação de Polaridade: JOGO COMPLETO: BAYERN DE MUNIQUE X BAYER LEVERKUSEN | RODADA 5 | BUNDESLIGA 2024-2025



Ajuste por Volume (WSI): JOGO COMPLETO: BAYERN DE MUNIQUE X BAYER LEVERKUSEN | RODADA 5 | BUNDESLIGA 2024-2025



Conclusão do Estudo de Caso

Em uma partida individual, ambas as métricas apresentam alta volatilidade. O WSI ajuda a suavizar janelas de baixa atividade, concentrando o sinal nos momentos de maior interatividade coletiva. Essas flutuações refletem a narrativa emocional da transmissão, reagindo aos acontecimentos do jogo em tempo real.

8. Conclusão Técnica — Parte I (Chat)

A análise exploratória demonstra que o YouTube Live Chat funciona como um sensor social responsivo. O pipeline combinando rótulos inteligentes e classificação escalável permitiu processar o dataset de forma eficiente, gerando métricas que acompanham o engajamento da massa digital durante a Bundesliga na CazéTV.

Parte II — EDA dos Dados de Eventos de Campo

Esta seção expande a análise para os **dados de eventos esportivos** (Gradient), cobrindo as **63 partidas mapeadas** aos vídeos da CazéTV. O objetivo é construir as métricas contínuas de desempenho — **xT** e **Momentum** — que serão correlacionadas ao sentimento do chat nas RQs do projeto.

Perguntas de Pesquisa:


- **RQ1:** Qual a correlação temporal entre o sentimento do chat e métricas de campo (xT e Momentum)?
- **RQ2:** Flutuações de sentimento precedem estatisticamente eventos discretos críticos (gols, cartões)?


9. Ingestão e Estruturação dos Dados de Eventos

Eventos de posse carregados: 126,325
Eventos discretos (gols/cartões/subs): 1,025
Linhas de Momentum: 5,911
xT grid shape: (16, 12), max xT: 0.2431

	video_id	game_id	period	match_minute	clock_s	home_team	pe_type	pe_type_label	shot
0	2Nja0HmgtDI	32677	1	0	1	True	IT	Interceptação	
1	2Nja0HmgtDI	32677	1	0	1	True	PA	Passe	
2	2Nja0HmgtDI	32677	1	0	6	True	CH	Duelo	
3	2Nja0HmgtDI	32677	1	0	6	True	PA	Passe	
4	2Nja0HmgtDI	32677	1	0	9	True	PA	Passe	

10. EDA dos Eventos — Distribuição e Localização





Análise

1. **Tipos:** Passes (~60%) dominam; chutes < 2%, porém são os eventos de maior relevância para xT.
2. **Volume Temporal:** Queda abrupta no intervalo, retomada imediata no 2º tempo, pico nos acréscimos.
3. **Heatmap:** Chutes concentrados na área (x > 88m); gols próximos ao ponto de penalidade e pequena área.



11. Expected Threat (xT)

O **xT** quantifica o perigo criado por cada ação em campo, baseado na probabilidade de marcar a partir daquela zona:



$$xT(x, y) = s(x, y) \cdot g(x, y) + (1 - s(x, y)) \cdot xT_{\text{prev}}(x, y)$$

Onde $s(x, y)$ é a taxa de chute e $g(x, y)$ a taxa de gol por zona. O grid é calculado **empiricamente** com os 306 jogos do dataset.

Total de eventos (306 jogos): 581,503



xT máximo (por zona): 0.2431



Análise do xT



- **Mapa de Calor:** O grid confirma que o perigo cresce exponencialmente dentro da área ($x > 88m$), com o pico no centro da pequena área.
- **Por Tipo:** Chutes têm o maior xT médio (esperado), seguidos de cruzamentos e conduções avançadas. Passes simples têm xT ~ 0 .
- **Home Advantage:** A curva de xT do mandante tende a ser ligeiramente superior, especialmente no 1º tempo — consistente com a vantagem do campo na literatura.

12. Momentum de Jogo

O **Momentum** captura o diferencial de pressão entre as equipes numa janela deslizante de $W = 5$ minutos:

$$\text{Momentum}(t) = \sum_{\tau=t-5}^t xT_{\text{home}}(\tau) - \sum_{\tau=t-5}^t xT_{\text{away}}(\tau)$$

Esta métrica será o sinal de campo para **RQ1** (correlação com sentimento) e **RQ2** (predição de eventos).



Análise do Momentum e Preparação para as RQs

1. **Padrão Agregado:** O Momentum médio flutua em torno de zero (balanço esperado), com leve vantagem home nos primeiros minutos — consistente com a vantagem do campo em casa.
2. **Estudo de Caso:** No jogo de maior variância, as mudanças de sinal do Momentum frequentemente precedem ou coincidem com gols (linhas pontilhadas), evidenciando que **a pressão de campo precede o evento** — alinhado à hipótese da RQ2.
3. **Eixo Temporal Compartilhado:** Tanto o Momentum quanto as métricas de sentimento (WSI, Seção 5) operam na resolução de **1 minuto de jogo**, permitindo alinhamento direto via `match_minute`.

Sinal	Resolução	Próximo Passo
WSI do Chat	1 min/jogo	RQ1: Cross-correlation WSI × Momentum
Momentum (xT)	1 min/jogo	RQ1 + RQ2
Eventos Discretos (Gols/Cartões)	timestamp exato	RQ2: Janela pré-evento

13. Conclusão Geral

Este notebook estabelece o **framework completo de dados** para as análises das RQs:

Componente	Métrica	Fonte
Sentimento do Chat	Polaridade, WSI	YouTube Live Chat (246k msgs, 63 jogos)
Perigo de Campo	xT por zona e por minuto	Gradient Events (63 jogos mapeados)
Pressão Relativa	Momentum (rolling 5min)	Gradient Events
Eventos Discretos	Gols, Cartões, Substituições	Gradient Events

Próximos Passos (TP3):

- **RQ1:** Cross-correlation entre WSI e Momentum por minuto de jogo (Pearson + Dynamic Time Warping).
- **RQ2:** Análise de janelas de sentimento pré-evento (t–5 a t–1 min antes de gols/cartões) via teste de hipótese (Mann-Whitney U).