

TP3: Modelagem e Análise de Dados (Relatório de Progresso e Validação)


Grupo: Alvaro, Dani, Igor, Ivan, Vitor

Data: 02 de Junho de 2026

Disciplina: CDAF

1. Estratégia de Modelagem

Para abordar o desafio de **Análise de Sentimento Multi-classe** (Positivo, Negativo, Neutro) em live chats do YouTube (especificamente transmissões da CazéTV), adotamos uma estratégia baseada em **Destilação de Conhecimento (Knowledge Distillation)**. O chat de futebol apresenta desafios únicos, como uso de gírias locais ("bagre", "jogar de terno"), termos de aposta ("green", "red", "odd"), sarcasmo e alta velocidade de envio de mensagens.



O pipeline de modelagem foi estruturado da seguinte forma: 1. **Construção do Golden Set Humano:** 5 rotuladores do grupo anotaram de forma independente comentários em pares. Apenas comentários com 100% de consenso foram selecionados, gerando uma base de validação altamente confiável de **652 mensagens**. 2. **Alinhamento do Teacher Model (Llama-3.1-8B-FP8):** Refinamos um prompt estruturado contendo regras explícitas para gírias esportivas, pouca carga emocional (classe Neutro por padrão) e exemplos few-shot. 3. **Geração de Dados Sintéticos:** O Llama rotulou um conjunto aleatório de **2.000 mensagens** de chat extraídas dos dados brutos. 4. **Treinamento do Student Model (BERTimbau-base):** Treinamos o BERTimbau-base (~110M parâmetros) de forma supervisionada sobre o dataset de 2k mensagens rotuladas pelo LLM.

O Prompt do Llama (Teacher Model)

Abaixo, o prompt completo de sistema estruturado para alinhar o modelo Llama 3.1 com a intuição humana. As seções estão destacadas por cores:

[1. DEFINIÇÃO DE PAPEL / PERSONA]

Você é um especialista em análise de sentimentos para chats de futebol da CazéTV.
Seu objetivo é classificar comentários seguindo o consenso de especialistas humanos.

[2. REGRA GERAL - VIÉS DE NEUTRALIDADE]

REGRA GERAL (O DEFAULT É NEUTRO):

Se o comentário NÃO contiver uma emoção forte e clara (positiva ou negativa), ele DEVE ser classificado como 1 (NEUTRO).

[3. CATEGORIAS DETALHADAS]

CATEGORIAS DETALHADAS:

0 (NEGATIVO): Apenas se houver toxicidade, raiva, ironia ácida ou decepção evidente:

- Frustração real com o andamento do jogo ou perda de apostas (ex: 'tomei red', 'esquece', 'perdi tudo', 'essa ambas tá difícil').
- Siglas de xingamento/irritação (ex: 'TNC', 'FDP', 'VTNC') ou gírias de aposta estragada (ex: 'lasca a bet').
- Críticas de desempenho ou sarcasmo contra jogadores/times (ex: 'kane deve estar assistindo TV', 'não fez nada até agora', 'brigou com a mulher', 'time medíocre').
- Reclamações contra a arbitragem, marcações de falta ou VAR (ex: 'foi falta no goleiro', 'máfia', 'roubo').
- Provocações hostis entre torcidas rivais (ex: 'vai pipocar de novo', 'sem mundial').

1 (NEUTRO): Comentários comuns, perguntas, curiosidades, mensagens de sistema e conversas gerais sem forte carga emocional:

- Perguntas e dúvidas informativas sobre o jogo ou regras (ex: 'Sesko chutou a gol?', 'é tipo Botafogo SP ou RJ?').
- Fatos objetivos sem opinião emocional (ex: 'Leverkusen está invicto', 'o jogo começou').
- Mensagens do sistema ou leituras mecânicas (ex: 'Thanks for subscribing Julio Cesar').
- Pedidos ou saudações simples sem emoção exagerada (ex: 'salve para Osasco', 'tô com saudades da Kings League').
- Palpites e análises de apostas meramente técnicos e secos (ex: 'odd de 1.50 pro Bayer', 'esse jogo é ambas marca').

2 (POSITIVO): Apenas comemoração, apoio, otimismo ou elogio claro:

- Elogios diretos ao visual, beleza, habilidade ou técnica (ex: 'Que homem gato', 'joga muito', 'goleiraço').
- Vibração por gol, jogadas boas ou apoio/torcida ao time (ex: 'GOL', 'vamo bayer', 'bayer é gigante').
- Expectativa positiva ou comemoração em apostas/gols (ex: 'preciso de 1 gol', 'hoje sai green', 'hoje tem gol', 'ambos marcam e Borussia ganha').
- Uso de emojis claramente alegres (:D, S2, 😊) que demonstram felicidade com a transmissão/jogo.

[4. DIRETRIZES DE DECISÃO / REGRAS DE BORDA]

DIRETRIZES DE DECISÃO:

- Se o comentário tiver torcida/apoio combinado com uma reclamação leve (ex: 'a máfia tá no Borussia, vamo Bayer'), a torcida prevalece -> classifique como 2.
- Elogiar ou enaltecer o potencial de um time comparativamente (ex: 'se não fosse o Barcelona, seria campeão', 'Bayer é o Flamengo da Alemanha') é um elogio -> classifique como 2.
- Perguntas informativas sobre estatísticas ou apostas (ex: 'Sesko chutou a gol?') são sempre 1, nunca 0 ou 2.
- Comentários zombando levemente, mas sem agressividade ou xingamento pesado, ou meras piadas

cotidianas são 1.

[5. EXEMPLOS FEW-SHOT COM CHAIN-OF-THOUGHT (CoT)]

EXEMPLOS DE CONCORDÂNCIA HUMANA:

1. "NÃO SAI 1 CARTÃO VELHO KKKKK 2X2 E NENHUM CARTÃO" -> Resposta: {"raciocinio": "Frustração clara e indignação com aposta/jogo.", "sentimento": 0}
2. "hoje tou sentindo o green já" -> Resposta: {"raciocinio": "Otimismo e expectativa positiva com aposta.", "sentimento": 2}
3. "Dei cash no jogo do leverkusen" -> Resposta: {"raciocinio": "Fato sobre ação técnica de aposta sem emoção.", "sentimento": 1}
4. "Schick cabeça de lego kkkkkkkkk" -> Resposta: {"raciocinio": "Apelido depreciativo / insulto a jogador.", "sentimento": 0}
5. "preciso de 1 gol aqui e 1 no jogo BESIKTAS" -> Resposta: {"raciocinio": "Torcida e expectativa ativa por gols.", "sentimento": 2}
6. "Botafogo vai pipocar de novo" -> Resposta: {"raciocinio": "Provocação pejorativa prevendo fracasso do time.", "sentimento": 0}
7. "eu já tomei red hj no fenerbahce" -> Resposta: {"raciocinio": "Lamentação / frustração por perda de aposta (red).", "sentimento": 0}
8. "Que homiiii gato. Nossa senhora" -> Resposta: {"raciocinio": "Elogio entusiasmado ao visual do jogador/técnico.", "sentimento": 2}
9. "o sesko chutou no gol rapaziada???" -> Resposta: {"raciocinio": "Pergunta informativa sobre estatística do jogo.", "sentimento": 1}
10. "era pra ter mostrado a linha da bola" -> Resposta: {"raciocinio": "Observação técnica sobre a transmissão sem agressividade.", "sentimento": 1}
11. "bayern sempre lasca a bet de td mundo" -> Resposta: {"raciocinio": "Frustração com o time estragando a aposta ('lascar a bet').", "sentimento": 0}
12. "essa ambas tá dificil TNC" -> Resposta: {"raciocinio": "Uso de sigla ofensiva (TNC) e frustração com aposta.", "sentimento": 0}
13. "Bayer é o flamengo da Alemanha" -> Resposta: {"raciocinio": "Comparação positiva enaltecendo a grandeza/popularidade do time.", "sentimento": 2}


[6. RESTRIÇÃO E FORMATO DE SAÍDA]

Responda EXCLUSIVAMENTE em JSON: {"raciocinio": "...", "sentimento": X}

2. Insights Preliminares

Os dados rotulados e analisados revelaram os seguintes comportamentos importantes: - **Subjetividade Extrema:** O cálculo da concordância inter-anotador humana (Cohen's Kappa) resultou em **0.472** (concordância moderada). Isso mostra que os torcedores interpretam a mesma mensagem de maneiras distintas (por exemplo, ironias ou termos de aposta neutros vs. comemoração). - **Desbalanceamento das Classes:** Há um forte desbalanceamento com predominância de comentários negativos (zoações e críticas) e neutros (perguntas técnicas e termos de aposta sem emoção). O sentimento positivo (celebração direta de gols e apoio) é menos frequente no fluxo contínuo do chat.

Abaixo, apresentamos a comparação da distribuição de sentimentos nos datasets:



Validação Estatística do Tamanho da Amostra

Para garantir a representatividade estatística das nossas conclusões frente ao universo total de **94.540 comentários**, validamos o tamanho das nossas amostras utilizando a fórmula de tamanho amostral para populações finitas com **95% de confiança** e variabilidade máxima de população ($P = 0.5$):

$$n_{\text{ajustado}} = \frac{n}{1 + (n - 1)/N} \quad \text{ONDE} \quad n = \frac{Z^2 \cdot P \cdot (1 - P)}{E^2}$$

- **Golden Set Humano (N = 652)**: Supera com folga o limite de **383 amostras** exigido para o erro amostral padrão de **5%**, posicionando-se em uma margem de erro aproximada de **3,8%**. Isso garante que a nossa base de validação humana é estatisticamente robusta.
- **Dataset de Treino Sintético (N = 2.000)**: Atinge uma margem de erro de apenas **2,18%** (muito próxima do patamar exigente de 2%), garantindo que o modelo BERTimbau foi exposto a uma amostragem altamente representativa do comportamento geral do chat para seu treinamento supervisionado.

3. Métricas Iniciais

Escolha e Justificativa das Métricas

Para avaliar os modelos em relação aos labels humanos consensuais, selecionamos três métricas: 1. **Acurácia**: Taxa geral de acertos do modelo. 2. **F1-Score (Weighted)**: Nossa métrica principal. Trata as classes de maneira proporcional ao seu suporte, garantindo que o modelo seja penalizado adequadamente se falhar na classe minoritária (Positivo), contornando o desbalanceamento. 3. **Cohen's Kappa**: Mede a concordância corrigindo o acerto ao acaso. É fundamental para avaliar a consistência da IA frente a anotações subjetivas.


Resultados de Avaliação (Golden Set)

Abaixo, consolidamos a concordância entre os rotuladores humanos e os modelos:


Relação	Métrica de Concordância	Valor	Nível de Concordância
Humano vs Humano	Cohen's Kappa Global	0.472	Moderada
Baseline vLLM (Qwen 7B) vs Humano	Cohen's Kappa / Acurácia	0.501 / 69.0 %	Moderada
Llama-3.1-8B-FP8 (Otimizado) vs Humano	Cohen's Kappa / Acurácia	0.690 / 80.2 %	Substancial
BERTimbau (Destilado) vs Humano	Cohen's Kappa / Acurácia	0.698 / 80.8 %	Substancial

Nota: No dataset fundido (712 exemplos incluindo duplicatas), o BERTimbau destilado obteve 80.8% de acurácia e 0.698 de Cohen's Kappa, ligeiramente superando o seu próprio professor Llama 8B (80.2% de acurácia e 0.690 de Kappa).

Abaixo estão as matrizes de confusão obtidas na avaliação:



Matriz de Confusão: Llama 3.1 8B FP8



Matriz de Confusão: BERTimbau (Destilado)

4. Próximos Passos

Estabelecemos o seguinte cronograma e atividades para as próximas etapas do projeto:

Atividade	Objetivo
Refinamento do Golden Set	Resolver divergências de anotações humanas (10% restantes) para expandir base de validação.
Tuning do BERTimbau	Experimentar otimizadores e scheduling de learning rate para estabilizar o treinamento.
Integração Final de Features	Cruzar o sentimento médio do chat em blocos de tempo com o momentum (xT) e eventos da partida.
Relatório Final e Dashboard	Entrega da análise consolidada e do painel interativo.